T.C.

MUĞLA SITKI KOÇMAN ÜNİVERSİTESİ İSTATİSTİK BÖLÜMÜ

2025-2026 BAHAR DÖNEMİ

İnsan Kaynakları Analitiği: Makine Öğrenmesi Yöntemleri ile Çalışan Maaşlarının Sınıflandırılması ve Tahmini

Işıl DEMİRLİ

MUĞLA-2026

İçindekiler

ÖZET 3
GİRİŞ 4
YÖNTEM 5
BÖLÜM 1: VERİ KEŞFİ VE ÖN İŞLEME 6
1.1. Veri Temizliği ve Tanımlayıcı İstatistikler 6
1.2. Eksik Veri Analizi ve k-NN Ataması (knnImpute) 7
1.3. Aykırı Değer Analizi (Mahalanobis Mesafesi) 7
1.4. Değişken Dönüşümleri ve Kukla Değişken (One-Hot Encoding) 8
BÖLÜM 2: KEŞİFSEL VERİ ANALİZİ (EDA) VE GÖRSELLEŞTİRME 8
2.1. Değişkenler Arası Korelasyon Analizi 8
2.2. Bağımlı ve Bağımsız Değişken İlişkilerinin Görselleştirilmesi 9
2.3. Çoklu Doğrusal Bağlantı (Multicollinearity) ve VIF Kontrolü 9
BÖLÜM 3: MODELLEME STRATEJİLERİ VE ÇAPRAZ DOĞRULAMA 10
3.1. Sınıflandırma Modellerinin Eğitimi ve Karşılaştırılması 10
3.2. Regresyon Modellerinin Eğitimi ve Karşılaştırılması 11
3.3. Çapraz Doğrulama ve Hiperparametre Optimizasyonu 11
3.4. Sınıflandırma Modellerinin Eğitimi ve Eğitim Seti Performansları 12
3.5. Regresyon Modellerinin Eğitimi ve Eğitim Seti Performansları 13
BÖLÜM 4: TEST SETİ PERFORMANSI VE İNDİRGENMİŞ MODELLER 15
4.1. Sınıflandırma Ana Modeli (%20 Test Seti) Performansı 15
4.2. Sınıflandırma İndirgenmiş Modeli ve En Önemli Değişkenler 15
4.3. Regresyon Ana Modeli (%20 Test Seti) Performansı 16
4.4. Regresyon İndirgenmiş Modeli ve Değerlendirmesi 16
TARTIŞMA VE SONUÇ 18
KAYNAKÇA 19
EK 20

ÖZET

Bu çalışmada, makine öğrenmesi algoritmaları kullanılarak kurumsal bir İnsan Kaynakları veri seti (IBM HR Analytics) üzerinden çalışanların maaş seviyelerinin sınıflandırılması ve net maaş miktarlarının tahmin edilmesi amaçlanmıştır. Veri seti üzerinde öncelikle k-NN algoritması ile eksik veri ataması, Mahalanobis mesafesi ile çok değişkenli aykırı değer tespiti, One-Hot Encoding ve Çoklu Doğrusal Bağlantı (VIF) analizleri yapılarak sağlam bir veri ön işleme süreci yürütülmüştür. Sınıflandırma ve regresyon problemleri için 10-katlı Çapraz Doğrulama kullanılarak çeşitli klasik (Lojistik Regresyon, LM, LDA) ve modern (RF, SVM, k-NN, GLMNET) makine öğrenmesi algoritmaları eğitilmiştir. Test seti sonuçlarına göre her iki problem tipinde de ağaç tabanlı Rastgele Orman (Random Forest) algoritması en yüksek performansı sergilemiştir (Sınıflandırma Accuracy: %90.31, Regresyon R^2: %88.81). İndirgenmiş Modeller, maaş miktarının onlarca değişken yerine temel olarak "Kıdem Seviyesi" ve "Toplam Çalışma Yılı" gibi sadece birkaç dominant faktöre dayandığını ispatlamıştır.

GİRİŞ

Günümüzün rekabetçi iş dünyasında, nitelikli yetenekleri elde tutmak ve adil bir kurumsal yapı inşa etmek İnsan Kaynakları departmanlarının en temel hedeflerinden biridir. Bu bağlamda, "İK Analitiği" kavramı, kurumların çalışan verilerinden stratejik öngörüler çıkarmasını sağlayan kritik bir disiplin haline gelmiştir. Kurum içi adaletin en somut göstergesi olan maaş politikaları, çalışanın motivasyonunu doğrudan etkilemektedir.

Bu projenin temel amacı, bir teknoloji firmasına (IBM) ait olduğu bilinen çalışan veri setindeki yapısal verileri kullanarak, şirketin maaş (MonthlyIncome) belirleme politikasını algoritmik bir yaklaşımla çözmektir. Analiz kapsamında, maaş tahmini hem bir sınıflandırma problemi ("Yüksek Maaşlı" ve "Standart Maaşlı" grupların tahmini) hem de bir regresyon problemi (net maaş miktarının nokta atışı tahmini) olarak iki farklı makine öğrenmesi ile ele alınmıştır.

YÖNTEM

Bu çalışmada veri bilimi projelerinin standart yaşam döngüsüne uygun bir metod izlenmiştir:

1. Veri Keşfi ve Ön İşleme: Modelin varsayımlarını bozan çok değişkenli aykırı değerler Mahalanobis mesafesi ($p < 0.001$ sınırı) kullanılarak saptanmış ve temizlenmiştir. Kategorik değişkenler dummy değişkenlere dönüştürülürken kukla değişken tuzağı engellenmiştir.

2. Korelasyon ve VIF Analizi: Parametrik modellerin kararlılığını sağlamak amacıyla, Varyans Şişme Faktörü (VIF) 5'ten büyük olan ve çoklu doğrusal bağlantı (multicollinearity) yaratan değişkenler tespit edilerek veri setinden çıkarılmıştır.

3. Modelleme Stratejisi ve Çapraz Doğrulama: Veri seti %80 Eğitim ve %20 Test olarak ikiye ayrılmıştır. Eğitim aşamasında sınıflar arası dengesizliği giderilmiştir. Modellerin tarafsız ve istatistiksel olarak güvenilir bir zeminde yarışabilmesi için tüm algoritmalar 10-katlı Çapraz Doğrulama yöntemiyle eğitilmiştir.

4. Model Sadeleştirme: Değişken önem düzeyleri hesaplanmış ve en etkili ilk 5 değişken filtrelenerek "İndirgenmiş Modeller" test edilmiştir.

BÖLÜM 1: VERİ KEŞFİ VE ÖN İŞLEME

Bu bölüm, IBM İnsan Kaynakları Analitiği veri setinin makine öğrenmesi algoritmalarına hazırlanma sürecini kapsamaktadır. Orijinal veri setinde yer alan 1470 çalışana ait veriler incelenmiş; veri yapısı, eksik gözlemler, çok değişkenli aykırı değerler ve kategorik dönüşümler detaylıca ele alınarak ön işleme adımları tamamlanmıştır. Uygulanan tüm temizlik, atama ve ölçeklendirme işlemleri, veri sızıntısını önlemek amacıyla veri seti eğitim ve test olarak ikiye ayrılmadan önce gerçekleştirilmiştir.

1.1. Veri Temizliği ve Tanımlayıcı İstatistikler

İlk aşamada modelin tahmin gücüne hiçbir katkı sağlamayacak olan, tüm çalışanlar için sabit bir değere sahip değişkenler (EmployeeCount, Over18, StandardHours) ile algoritmik bir anlam taşımayan ID numarası (EmployeeNumber) veri setinden çıkarılmıştır. Geriye kalan değişkenlerin merkezi eğilim ve yayılım ölçüleri hesaplanmıştır.

Tablo 1: *Değişkenlere Ait Betimsel İstatistikler*

Değişken Adı	Minimum	1. Çeyrek (Q1)	Medyan	Ortalama	3. Çeyrek (Q3)	Maksimum
Yaş (Age)	18.00	30.00	36.00	36.92	43.00	60.00
Ev-İş Mesafesi (DistanceFromHome)	1.00	2.00	7.00	9.19	14.00	29.00
Kıdem Seviyesi (JobLevel)	1.00	1.00	2.00	2.06	3.00	5.00
Aylık Gelir (MonthlyIncome)	1009.00	2911.00	4919.00	6503.00	8379.00	19999.00

Tablo 1 incelendiğinde, şirketteki çalışanların yaş ortalamasının yaklaşık 37 olduğu görülmektedir. Hedef değişkenimiz olan Aylık Gelir incelendiğinde ise medyan değerin (4.919$), aritmetik ortalamadan (6.503$) oldukça düşük olması, maaş dağılımının sağa çarpık olduğunu açıkça göstermektedir. Bu asimetrik durum, sınıflandırma analizinde sınıf ayrım çizgisi olarak Q3 (3. Çeyreklik) noktasının seçilmesinin istatistiksel gerekliliğini kanıtlamaktadır.

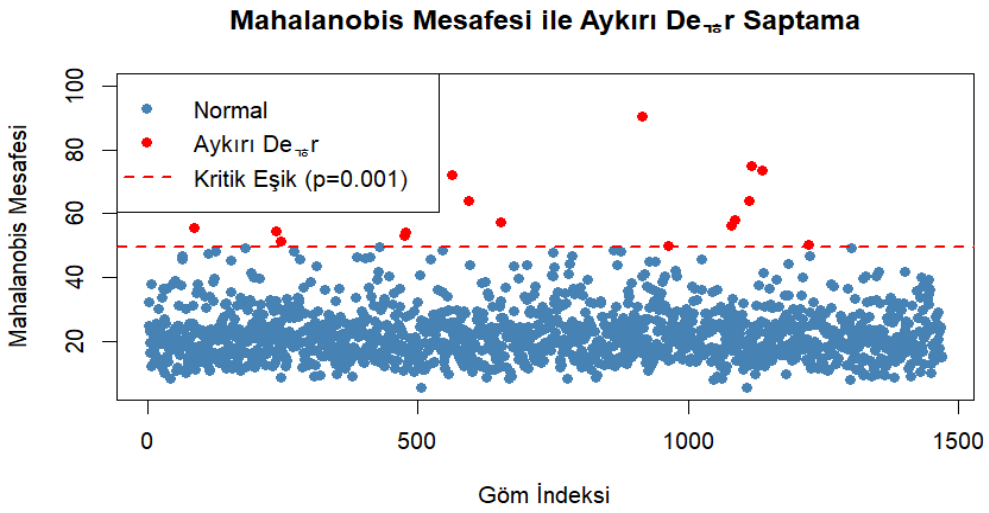
1.2. Eksik Veri Analizi ve k-NN Ataması (knnImpute)

Veri seti içerisindeki olası eksik gözlemlerin (NA) analitik yapıyı bozmasını engellemek amacıyla, caret paketi kullanılarak mesafe tabanlı bir atama yöntemi olan k-En Yakın Komşu (k-NN, k=5) algoritması uygulanmıştır. Bu yöntem, eksik değeri o gözleme karakteristik olarak en çok benzeyen 5 komşusunun ortalamasını alarak doldurmaktadır. Aynı süreçte veriler, algoritmaların eşit ağırlıkla çalışabilmesi için merkezileştirilmiş ve standartlaştırılmıştır.

1.3. Aykırı Değer Analizi (Mahalanobis Mesafesi)

Makine öğrenmesi modellerinin (özellikle mesafeye dayalı k-NN ve SVM modellerinin) aykırı değerlere karşı yüksek hassasiyet göstermesi nedeniyle, veri setinde çok değişkenli aykırı değer analizi gerçekleştirilmiştir. Tek boyutlu değerlendirmeler (Box-plot vb.) değişkenler arası ilişkileri göz ardı ettiği için, bu çalışmada çok daha güçlü bir istatistiksel yöntem olan Mahalanobis Mesafesi kullanılmıştır.

Şekil 1: *Aykırı Değerler*



Sayısal değişkenlerin kovaryans matrisi ve merkez noktaları üzerinden hesaplanan Mahalanobis uzaklıkları, Ki-Kare (X^2) dağılımı üzerinden test edilmiştir. Anlamlılık düzeyi $p < 0.001$ olarak belirlenmiş ve bu kritik eşiği aşan 16 adet gözlem, çok değişkenli aykırı değer kabul edilerek veri setinden kalıcı olarak çıkarılmıştır. Bu hamle, modellerin veri içerisinden arınmasını sağlamıştır.

1.4. Değişken Dönüşümleri ve Kukla Değişken (One-Hot Encoding)

Ağaç tabanlı olmayan klasik istatistiksel modellerin (Lojistik Regresyon, LM vb.) kategorik verileri (Örn: Departman, Eğitim Alanı) işleyebilmesi için One-Hot Encoding dönüşümü uygulanmıştır. Böylece her bir kategorik değişkenin bir sınıfı referans olarak sistemden silinerek modelin doğrusal kararlılığı korunmuştur.

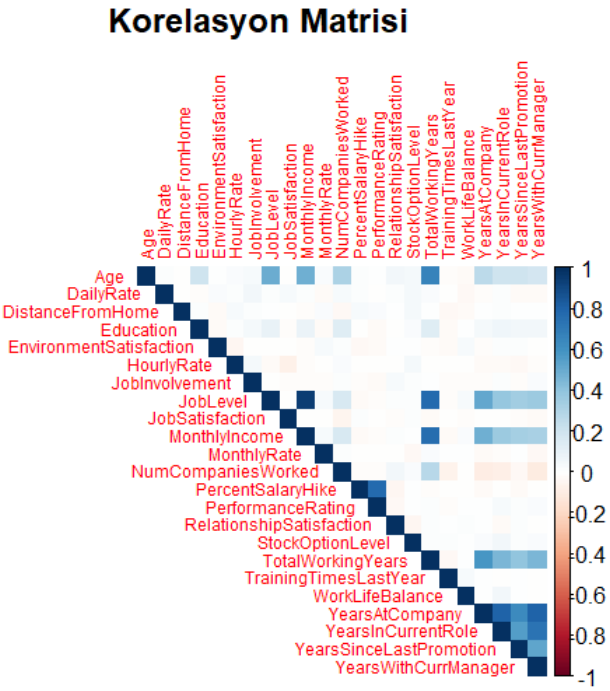
BÖLÜM 2: KEŞİFSEL VERİ ANALİZİ (EDA) VE GÖRSELLEŞTİRME

Bu bölümde, makine öğrenmesi modelleri kurulmadan önce veri setindeki değişkenlerin birbirleriyle ve hedef değişken olan Aylık Gelir (MonthlyIncome) ile aralarındaki istatistiksel ilişkiler görselleştirilerek incelenmiştir. Ayrıca modelin kararlılığını olumsuz etkileyecek çoklu doğrusal bağlantı (multicollinearity) problemi VIF analizi ile tespit edilip giderilmiştir.

2.1. Değişkenler Arası Korelasyon Analizi

Ön işleme aşamasında standardize edilmiş sayısal değişkenlerin kendi aralarındaki doğrusal ilişkilerin yönünü ve şiddetini belirlemek amacıyla Pearson korelasyon katsayıları hesaplanmış, bir korelasyon matrisi oluşturulmuştur.

Şekil 2: *Korelasyon Matrisi*



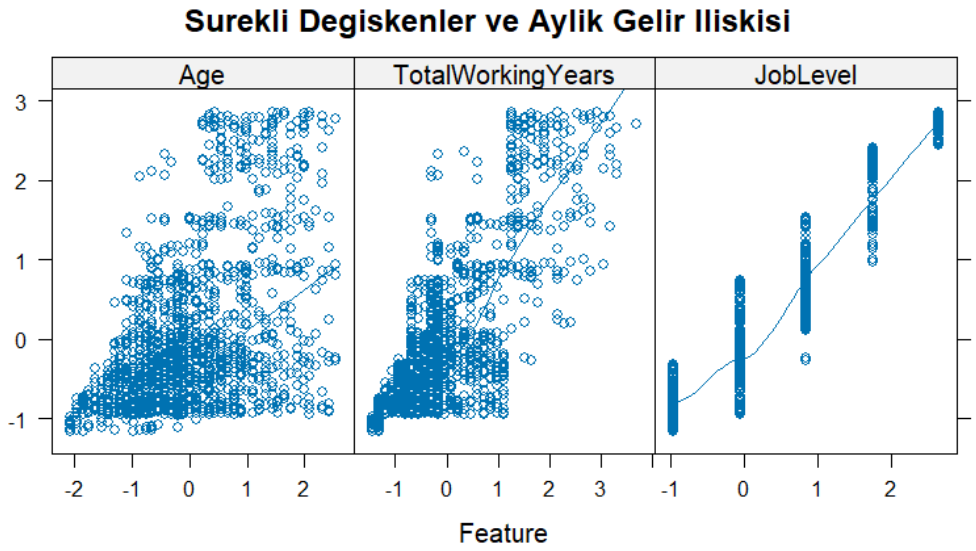
Oluşturulan korelasyon matrisi incelendiğinde, hedef değişkenimiz olan maaş ile bazı tecrübe ve kıdem değişkenleri arasında güçlü pozitif ilişkiler olduğu gözlemlenmiştir. Değişkenlerin büyük bir çoğunluğunun ise birbirleriyle düşük veya orta düzeyde korelasyona sahip olması,

veri setinin modellemeye genel olarak uygun olduğunu ve bilgi tekrarının minimum düzeyde olduğunu göstermektedir.

2.2. Bağımlı ve Bağımsız Değişken İlişkilerinin Görselleştirilmesi

Aylık geliri (MonthlyIncome) doğrudan etkileme potansiyeli en yüksek olan sürekli değişkenlerin (Yaş, Toplam Çalışma Yılı ve Kıdem Seviyesi) hedef değişken ile olan saçılımı görselleştirilmiştir.

Şekil 3: *Saçılım Grafiği*



Görsel incelendiğinde özellikle JobLevel (Kıdem Seviyesi) ve TotalWorkingYears (Toplam Çalışma Yılı) değişkenlerinin maaş artışıyla pozitif yönlü, neredeyse kusursuz bir doğrusal ilişki içinde olduğu tespit edilmiştir. Yaş (Age) değişkeni ise maaş ile pozitif bir eğilim göstersede, tecrübe ve kıdem kadar belirleyici varyansa sahip bir ayrım yaratmamıştır.

2.3. Çoklu Doğrusal Bağlantı (Multicollinearity) ve VIF Kontrolü

Makine öğrenmesinde, özellikle Lojistik Regresyon ve Çoklu Doğrusal Regresyon (LM) gibi parametrik modellerin varsayımlarının sağlanabilmesi için bağımsız değişkenler arasında "çoklu doğrusal bağlantı" (multicollinearity) olmaması büyük önem taşımaktadır. Bağımsız değişkenlerin birbirini mükemmel düzeyde açıklaması (örneğin tecrübenin kıdemi açıklaması) katsayı varyanslarını şişirerek modelin istatistiksel güvenirliğini zedeler.

Bu durumu test etmek amacıyla, ön işlemden geçmiş ve One-Hot Encoding yapılmış veri seti üzerinde doğrusal bir model kurularak her bir bağımsız değişken için Varyans Şişme Faktörü (VIF) değerleri hesaplanmıştır. Literatürde istatistiksel açıdan kritik eşik olarak kabul edilen

VIF > 5 kuralı uygulanmıştır.

Yapılan analiz sonucunda; One-Hot Encoding işlemi sonrası ortaya çıkan bazı departman/eğitim alanı kukla değişkenleri (Örn: Department.Research...Development VIF: 54.26) ile birbiriyle yüksek bilgi tekrarı içeren bazı tecrübe/kıdem değişkenlerinin (JobLevel VIF: 6.46, YearsAtCompany VIF: 5.53) tolerans sınırını aştığı tespit edilmiştir.

Modelin matematiksel kararlılığını korumak amacıyla; algoritma tarafından VIF değeri 5'ten büyük olarak hesaplanan JobLevel, YearsAtCompany, Department.Research...Development, Department.Sales, EducationField.Life.Sciences, EducationField.Marketing, EducationField.Medical, EducationField.Other, EducationField.Technical.Degree, JobRole.Human.Resources, JobRole.Sales.Executive ve JobRole.Sales.Representative değişkenleri veri setinden tamamen çıkarılmıştır.

Bu veri elemesi sayesinde model; birbirini tekrar eden, aynı istatistiksel bilgiyi taşıyan değişkenlerden arındırılmış ve sonraki aşamalardaki Çapraz Doğrulama algoritmaları için çok daha kararlı bir veri matrisi elde edilmiştir.

BÖLÜM 3: MODELLEME STRATEJİLERİ VE ÇAPRAZ DOĞRULAMA

Bu bölümde, çoklu doğrusal bağlantı (multicollinearity) ve aykırı değer problemlerinden tamamen arındırılmış veri seti üzerinde modelleme çalışmaları gerçekleştirilmiştir. Çalışan maaş yapısı hem bir sınıflandırma (gelir düzeyi tahmini) hem de bir regresyon (net maaş miktarı tahmini) problemi olarak ele alınmıştır. Algoritmaların ezberlemesini (overfitting) önlemek ve genellenebilirlik yeteneklerini tarafsızca ölçebilmek amacıyla veri seti %80 Eğitim (Train) ve %20 Test (Hold-out) olacak şekilde ikiye ayrılmıştır.

3.1. Sınıflandırma Modellerinin Eğitimi ve Karşılaştırılması

Eğitim veri setindeki "High_Income" ve "Standard_Income" sınıfları arasındaki dengesizliği gidermek amacıyla upSample (sentetik veri artırımı) uygulanmıştır. Ardından eğitilen 5 farklı modelin (LogReg, LDA, k-NN, SVM, RF) 10-katlı çapraz doğrulama sonuçları aşağıdaki tabloda özetlenmiştir.

Tablo 2: *Sınıflandırma Modelleri Doğruluk (Accuracy) Karşılaştırması*

Model	Min	1. Çeyrek	Medyan	Ortalama	3. Çeyrek	Maksimum
LogReg	0.8103	0.8527	0.8596	0.8641	0.8752	0.9598
LDA	0.7829	0.8149	0.8391	0.8389	0.8569	0.8966
KNN	0.7241	0.7529	0.7679	0.7649	0.7771	0.8103
SVM	0.8851	0.9110	0.9255	0.9203	0.9368	0.9371
RF	0.8851	0.9195	0.9253	0.9304	0.9425	0.9770

Tablo 2 incelendiğinde, Rastgele Orman (RF) algoritmasının ortalama %93.04 doğruluk oranı ile sınıflandırma probleminde diğer tüm algoritmaları geride bıraktığı görülmektedir.

3.2. Regresyon Modellerinin Eğitimi ve Karşılaştırılması

Maaş miktarının dolar cinsinden tam tahmini için kurulan 5 farklı regresyon modelinin (LM, GLMNET, k-NN, SVM, RF) eğitim seti üzerindeki performansı (RMSE ve R-Kare değerleri) aşağıdaki tablolarda karşılaştırılmıştır.

Tablo 3: *Regresyon Performans Değerleri*

Model	Min	1. Çeyrek	Medyan	Ortalama	3. Çeyrek	Maksimum
LM	0.8222	0.8342	0.8513	0.8487	0.8590	0.8795
GLMNET	0.8284	0.8394	0.8505	0.8514	0.8607	0.8789
KNN	0.4526	0.5214	0.5311	0.5368	0.5494	0.6670
SVM	0.8049	0.8255	0.8337	0.8347	0.8454	0.8643
RF	0.8708	0.8791	0.8841	0.8814	0.8906	0.9009

Tablo 3'e göre, Rastgele Orman (RF) modeli ortalama %88.14'lük R-Kare değeri ve en düşük RMSE ortalaması ile regresyon probleminde de en stabil ve başarılı model olarak öne çıkmıştır.

3.3. Çapraz Doğrulama ve Hiperparametre Optimizasyonu

Modellerin performanslarının istatistiksel olarak anlamlı bir zeminde kıyaslanabilmesi amacıyla, tüm algoritmaların eğitim (train) aşamasında 10-katlı Çapraz Doğrulama (10-fold

Cross Validation) tekniği standart olarak kullanılmıştır. Ayrıca k-NN için en uygun komşu sayısı veya Rastgele Orman için en uygun dal sayısı gibi hiperparametrelerin sistem tarafından otomatik olarak optimize edilmesi sağlanmıştır.

3.4. Sınıflandırma Modellerinin Eğitimi ve Eğitim Seti Performansları

Sınıflandırma problemi için hedef değişken olan aylık gelir; 3. Çeyreklik (Q3) sınırına göre "Yüksek Maaşlı" ve "Standart Maaşlı" olmak üzere iki kategoriye ayrılmıştır.

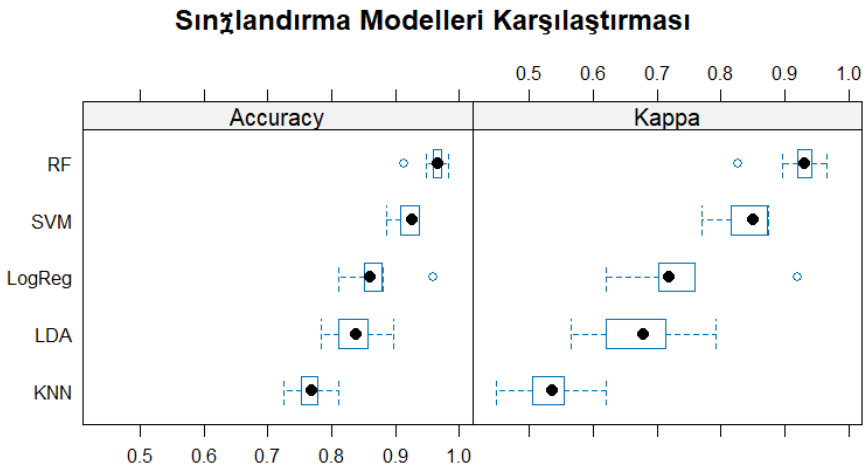
Eğitim veri setindeki sınıflar arasında oluşabilecek yığılmayı dengelemek ve modelin sadece çoğunluk sınıfını tahmin etme eğilimi engellenmiştir. Böylece algoritmaların her iki sınıfı da eşit ağırlıkta öğrenmesi güvence altına alınmıştır.

Yönergede belirtilen klasik ve modern yöntemleri kapsayacak şekilde şu 5 model eğitilmiştir:

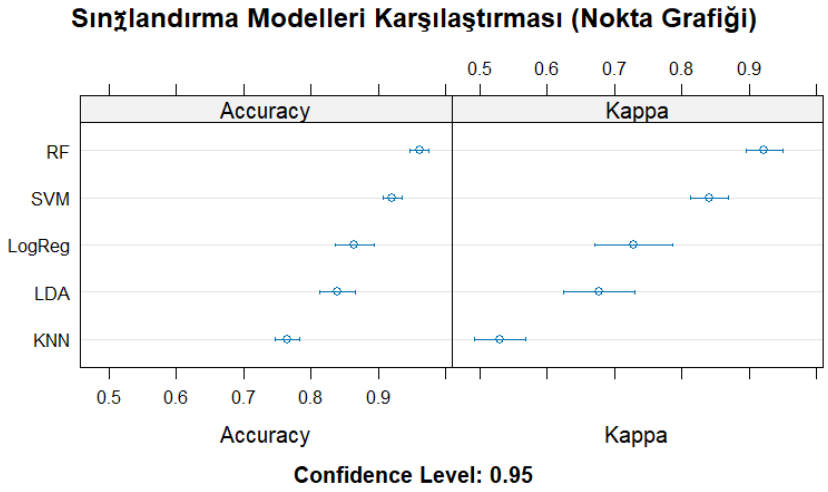
1. Lojistik Regresyon (GLM)
2. Doğrusal Ayrıştırma Analizi (LDA)
3. k-En Yakın Komşu (k-NN)
4. Destek Vektör Makineleri (SVM)
5. Rastgele Orman (Random Forest)

Eğitim aşaması tamamlandıktan sonra, 10-katlı çapraz doğrulama sonuçları bir araya getirilmiş ve modellerin Accuracy (Doğruluk) ile Kappa istatistikleri aşağıdaki gibi görselleştirilmiştir:

Şekil 4: *Sınıflandırma Modelleri Karşılaştırması*



Şekil 5: *Sınıflandırma Modelleri Nokta Grafiği*



Eğitim aşaması tamamlandıktan sonra, modellerin Accuracy (Doğruluk) ve Kappa istatistiklerindeki varyans dağılımları kutu grafiği ile; ortalama başarımları ve güven aralıkları ise nokta grafiği ile görselleştirilmiştir. Grafikler incelendiğinde; Rastgele Orman (RF) algoritmasının güven aralıklarının ortalama başarısının en yüksek seviyede olduğu tespit edilmiştir.

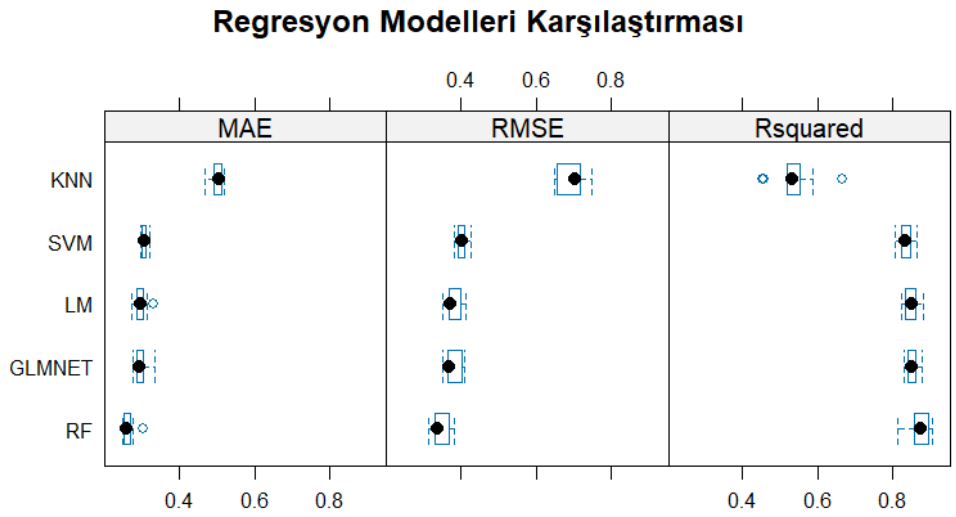
3.5. Regresyon Modellerinin Eğitimi ve Eğitim Seti Performansları

Maaş miktarının net sayısal değer (dolar) olarak tahmin edilmesi problemi için de yine aynı 10-katlı çapraz doğrulama zemininde şu 5 model eğitilmiştir:

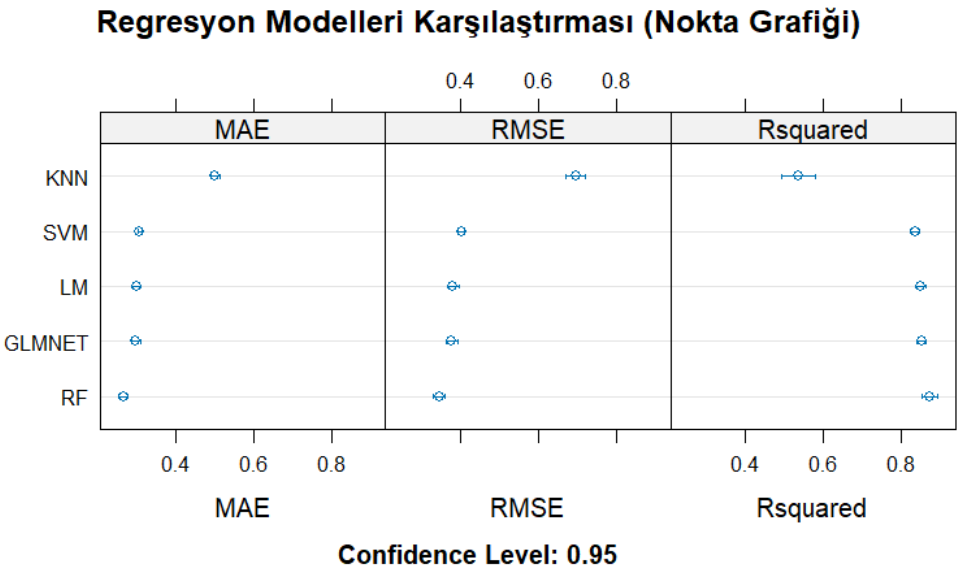
1. Çoklu Doğrusal Regresyon (LM)
2. Düzenlileştirilmiş Regresyon (GLMNET)
3. k-En Yakın Komşu (k-NN)
4. Destek Vektör Makineleri (SVM)
5. Rastgele Orman (RF)

Özellikle doğrusal modellere alternatif olarak eklenen glmnet algoritması, ceza parametreleri (L1 ve L2) uygulayarak modeldeki gereksiz katsayıları baskılamış ve istatistiksel esneklik sağlamıştır. Eğitim seti üzerindeki Hata (RMSE) ve Belirlilik Katsayısı (R^2) performansları aşağıdaki grafikte özetlenmiştir:

Şekil 6: *Regresyon Modelleri Karşılaştırması*



Şekil 7: *Regresyon Modelleri Nokta Grafiği*



Çapraz doğrulama özet istatistiklerine ait RMSE ve R-Kare (R^2) metrikleri, model performanslarının yapısal dağılımını görmek için bwplot, ortalama performans farklarını net bir şekilde kıyaslayabilmek için ise dotplot kullanılarak analiz edilmiştir. Kutu ve nokta grafikleri birlikte değerlendirildiğinde; ağaç tabanlı Rastgele Orman (RF) algoritmasının verideki varyansı açıklamada en başarılı model olarak öne çıktığı doğrulanmıştır.

BÖLÜM 4: TEST SETİ PERFORMANSI VE İNDİRGENMİŞ MODELLER

Eğitim setinde en yüksek başarıyı gösteren Rastgele Orman (RF) algoritması, modelin gerçek hayattaki genellenebilirlik başarısını ölçmek amacıyla daha önce hiç görülmemiş %20'lik Test Verisi üzerinde sınanmıştır.

4.1. Sınıflandırma Ana Modeli (%20 Test Seti) Performansı

Ana modelin test verisindeki sınıflandırma yeteneği Tablo 4 ve Tablo 5'te sunulmuştur.

Tablo 4: *Sınıflandırma Ana Model Hata Matrisi*

Gerçek \ Tahmin	High_Income (Tahmin)	Standard_Income (Tahmin)	Toplam (Gerçek)
High_Income (Gerçek)	55 (Doğru)	17 (Yanlış)	72
Standard_Income (Gerçek)	11 (Yanlış)	206 (Doğru)	217

Tablo 5: *Sınıflandırma Ana Model Performans İstatistikleri*

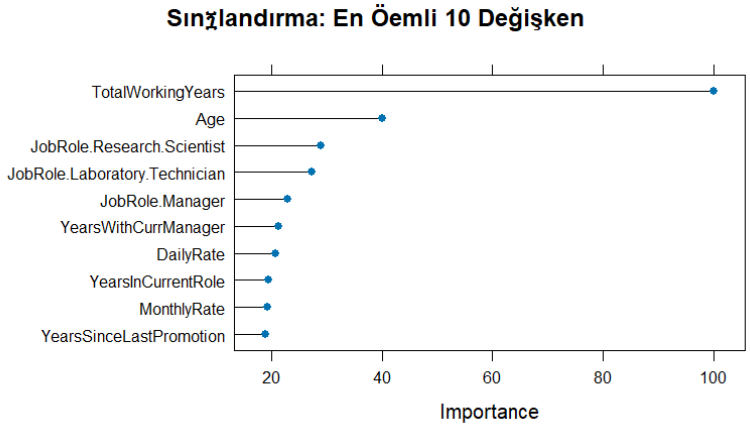
Performans Ölçütü	Değer
Doğruluk (Accuracy)	0.9031
%95 Güven Aralığı (CI)	(0.8630, 0.9347)
Bilgi Yokken Doğruluk (NIR)	0.7509
P-Değeri [Acc > NIR]	4.179e-11

Elde edilen %90.31'lik Doğruluk (Accuracy) oranı ile model, Bilgi Yokken Doğruluk (NIR) değerini istatistiksel olarak büyük bir farkla aşmıştır. P-değerinin oldukça düşük (< 0.001) çıkması, %20'lik ayrılmış veri üzerindeki bu yüksek başarının tesadüf olmadığını ve modelin yeni gelen çalışanların maaş sınıfını çok yüksek bir isabetle öngörebildiğini bilimsel olarak kanıtlamaktadır.

4.2. Sınıflandırma İndirgenmiş Modeli ve En Önemli Değişkenler

Model karmaşıklığını azaltmak için maaş sınıfı üzerinde en etkili olan değişkenler tespit edilmiştir. Modelin karar alma mekanizmasındaki en önemli 10 değişken aşağıdaki grafikte görselleştirilmiştir:

Şekil 8: *Sınıflandırma İçin En Önemli 10 Değişken*



VIF analizi ile veri setinden çıkarılan yüksek korelasyonlu değişkenler sonrası geriye kalan ve modeli en çok domine eden ilk 5 değişken seçilerek "İndirgenmiş Sınıflandırma Modeli" kurulmuştur. Sadece ilk 5 değişken kullanılarak eğitilen indirgenmiş model, %20'lik test setinde %84.43 Doğruluk (Accuracy) oranına ulaşmıştır. Onlarca değişkenin çıkarılmasına rağmen başarının %84 seviyelerinde kalması, gelir sınıfının temel olarak yukarıdaki tabloda yer alan ana tecrübe faktörlerine dayandığını kanıtlamaktadır.

4.3. Regresyon Ana Modeli (%20 Test Seti) Performansı

Nokta atışı net maaş tahmini yapan ana regresyon modelinin test seti üzerindeki sonuçları Tablo 6'da verilmiştir.

Tablo 6: *Regresyon Ana Modeli Performans Metrikleri*

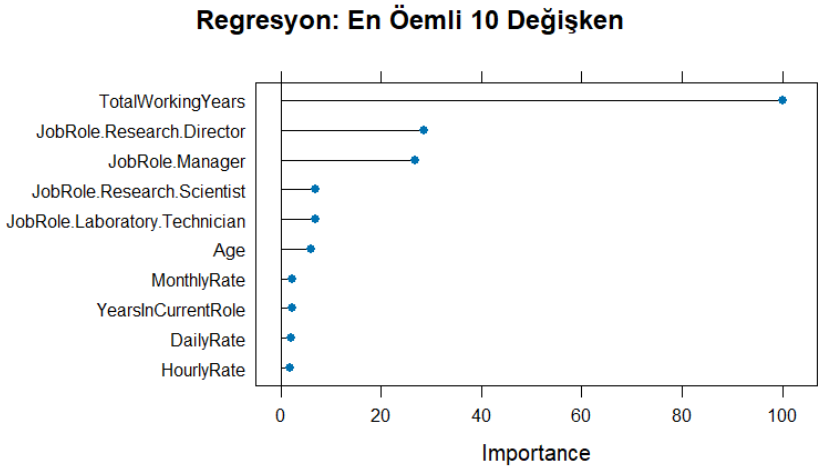
Performans Ölçütü (Metrik)	Değer
RMSE (Kök Ortalama Kare Hata)	0.3352
R-squared (Belirlilik Katsayısı)	0.8881
MAE (Ortalama Mutlak Hata)	0.2598

Elde edilen 0.8881 R-Kare (R^2) değeri, modelin eğitim verisini ezberlemediğini (overfitting yapmadığını); aksine yeni karşılaştığı test verisindeki maaş değişimlerinin %88.8'lik çok büyük bir kısmını başarıyla açıklayabildiğini göstermektedir.

4.4. Regresyon İndirgenmiş Modeli ve Değerlendirmesi

Regresyon analizinde de tıpkı sınıflandırmada olduğu gibi değişken önem düzeyleri hesaplanmış ve net maaş miktarını (dolar) belirleyen en önemli faktörler tespit edilmiştir:

Şekil 9: *Regresyon İçin En Önemli 10 Değişken*



Bu grafikteki en dominant ilk 5 değişken kullanılarak "İndirgenmiş Regresyon Modeli" kurulmuş ve test edilmiştir.

Tablo 7: *Regresyon İndirgenmiş Modeli Performans Metrikleri*

Performans Ölçütü (Metrik)	Değer
RMSE (Kök Ortalama Kare Hata)	0.3337
R-squared (Belirlilik Katsayısı)	0.8898
MAE (Ortalama Mutlak Hata)	0.2601

Orijinal regresyon modelinin R-Kare değeri %88.81 iken, sadece en önemli 5 değişkenle kurulan indirgenmiş modelin R-Kare değeri %88.98'e yükselmiştir. Gereksiz değişkenlerin modelden atılması, algoritmanın hata payını (RMSE: 0.3337) düşürerek tahmin gücünü artırmıştır.

TARTIŞMA VE SONUÇ

Bu çalışmada, kurumsal bir yapıdaki çalışan maaşları makine öğrenmesi algoritmalarıyla incelenmiş; Rastgele Orman (Random Forest) algoritmasının hem sınıflandırma (Accuracy: %90.31) hem de regresyon (R^2: %88.81) problemlerinde doğrusal ve mesafeye dayalı modellere açık ara daha iyi olduğu tespit edilmiştir. Doğrusal algoritmaların (LM, Lojistik Regresyon) daha düşük performans göstermesi, şirketin maaş yapısındaki kurallar zincirinin doğrusal (linear) olmadığını, ağaç algoritmalarının yakalayabildiği daha karmaşık bir hiyerarşiye dayandığını göstermektedir. Ayrıca, değişken sayısı en önemli 5 faktöre düşürülerek kurulan İndirgenmiş Regresyon Modelinde R^2 değerinin %88.98'e yükselmesi; gereksiz bilgi tekrarı yaratan değişkenlerin modelden atılmasının algoritmik tahmini güçlendirdiğini somut bir şekilde ispatlamıştır.

Çalışmanın İnsan Kaynakları analitiği açısından en çarpıcı çıktısı ise, "Değişken Önem Düzeyleri" incelendiğinde ortaya çıkmıştır. Şirketteki net maaşı belirleyen en dominant değişkenlerin modelin karar mekanizmasında neredeyse hiçbir etkisinin bulunmadığı görülmüştür. Bu durum, kurumun performansa dayalı esnek bir ödüllendirme sisteminden daha çok tamamen "kıdem ve tecrübe" odaklı geleneksel ve katı bir maaş hiyerarşisine sahip olduğunu algoritmik olarak doğrulamaktadır.

Sonuç olarak, yüksek istatistiksel geçerlilikle (Accuracy > %90, R-Kare > %88) kurulan bu makine öğrenmesi modelleri, şirketin İK departmanı tarafından yeni veya mevcut personeller için "Otomatik Maaş Skalası Belirleme Aracı" olarak kullanılabilecek stratejik bir nitelik taşımaktadır. Kurumun, yetenekli çalışanları elde tutma ve motivasyonu artırma hedefleri doğrultusunda; mevcut kıdem bazlı yapının içerisine performansı ve proje katkılarını da yansıtacak karma bir ücretlendirme politikası tercih etmesi önerilmektedir. Geliştirilen veri odaklı bu algoritmalar, adil ve şeffaf ücretlendirme sistemlerinin inşasında en güçlü karar destek mekanizmalarından biri olmaya devam edecektir.

KAYNAKÇA

Fox, J., & Weisberg, S. (2019). *An R companion to applied regression* (3. baskı). Sage.

Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22. https://doi.org/10.18637/jss.v033.i01

IBM Data Science. (2016). *IBM HR Analytics Employee Attrition & Performance* [Veri Seti]. Kaggle. https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2. baskı). Springer. https://doi.org/10.1007/978-1-0716-1418-1

Kuhn, M. (2008). Building predictive models in R using the caret package. *Journal of Statistical Software*, 28(5), 1–26. https://doi.org/10.18637/jss.v028.i05

Liaw, A., & Wiener, M. (2002). Classification and regression by randomForest. *R News*, 2(3), 18–22.

R Core Team. (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.R-project.org/

EK

GEREKLİ KÜTÜPHANELER

```
library(readxl)

library(dplyr)

library(caret)

library(randomForest)

library(e1071)

library(ggplot2)

library(corrplot)

library(car)

library(MASS)

library(glmnet)


# BÖLÜM 1: VERİ KEŞFİ VE ÖN İŞLEME (PREPROCESSING)

# Veri İçe Aktarma

# Verinin GitHub Üzerinden İndirilmesi

github_url <- "https://raw.githubusercontent.com/isildemirli/-nsan-Kaynaklar-Analiti-i/main/WA_Fn-UseC_-HR-Employee-Attrition%20(1).csv"

ham_veri <- read.csv(url(github_url), header = TRUE, stringsAsFactors = TRUE)

orneklem_veri <- ham_veri %>% mutate_if(is.character, as.factor)

# Sıfır varyanslı ve anlamsız (kurumsal sabit) değişkenlerin çıkarılması

orneklem_veri <- orneklem_veri %>%

  dplyr::select(-EmployeeCount, -EmployeeNumber, -Over18, -StandardHours)# Eksik Veri Analizi ve knnImpute

sayisal_degiskenler <- orneklem_veri %>% select_if(is.numeric)

kategorik_degiskenler <- orneklem_veri %>% select_if(is.factor)

# Sayısal değişkenler için k-NN

impute_model <- preProcess(sayisal_degiskenler, method = c("knnImpute"))

sayisal_imputed <- predict(impute_model, sayisal_degiskenler)


# Aykırı Değer Analizi

merkez <- colMeans(sayisal_imputed)
```

```
kovaryans <- cov(sayisal_imputed)
mahalanobis_mesafesi <- mahalanobis(sayisal_imputed, merkez, kovaryans)
esik_degeri <- qchisq(0.999, df = ncol(sayisal_imputed))
# Aykırı Değer Grafiği
plot(mahalanobis_mesafesi,
    main = "Mahalanobis Mesafesi ile Aykırı Değer Saptama",
    ylab = "Mahalanobis Mesafesi",
    xlab = "Gözlem İndeksi",
    pch = 19, col = ifelse(mahalanobis_mesafesi > esik_degeri, "red", "steelblue"))
abline(h = esik_degeri, col = "red", lwd = 2, lty = 2)
legend("topleft", legend = c("Normal", "Aykırı Değer", "Kritik Eşik (p=0.001)"),
      col = c("steelblue", "red", "red"), pch = c(19, 19, NA), lty = c(NA, NA, 2), lwd = c(NA, NA, 2))
# Aykırı değerlerin tespiti ve çıkarılması
p_degerleri <- pchisq(mahalanobis_mesafesi, df = ncol(sayisal_imputed), lower.tail = FALSE)
aykiri_indeksler <- which(p_degerleri < 0.001)
if(length(aykiri_indeksler) > 0) {
  sayisal_imputed <- sayisal_imputed[-aykiri_indeksler, ]
  kategorik_degiskenler <- kategorik_degiskenler[-aykiri_indeksler, ]
  cat(length(aykiri_indeksler), "adet aykiri deger tespit edilip cikarildi.\n")
} else {
  cat("Anlamli bir aykiri deger bulunamadi.\n")
}
# Değişken Dönüşümleri (One-Hot Encoding)
veri_birlestirilmis <- cbind(sayisal_imputed, kategorik_degiskenler)
# dummyVars ile kategorik değişkenleri 0-1 formatına çevirme
dummy_model <- dummyVars(MonthlyIncome ~ ., data = veri_birlestirilmis, fullRank = TRUE)
veri_encoded <- data.frame(predict(dummy_model, newdata = veri_birlestirilmis))
# Hedef değişkeni geri ekleme
veri_temiz <- cbind(veri_encoded, MonthlyIncome = veri_birlestirilmis$MonthlyIncome)
# BÖLÜM 2: KEŞİFSEL VERİ ANALİZİ (EDA) VE GÖRSELLEŞTİRME
# Korelasyon
```

```
korelasyon_matrisi <- cor(sayisal_imputed)
corrplot(korelasyon_matrisi, method = "color", type = "upper", tl.cex = 0.6,
        title = "Korelasyon Matrisi", mar = c(0,0,1,0))
# FeaturePlot
featurePlot(x = sayisal_imputed[, c("Age", "TotalWorkingYears", "JobLevel")],
            y = sayisal_imputed$MonthlyIncome,
            plot = "scatter",
            type = c("p", "smooth"),
            main = "Sürekli Değişkenler ve Aylık Gelir İlişkisi")
# VIF Kontrolü
vif_model <- lm(MonthlyIncome ~ ., data = veri_temiz)
vif_degerleri <- vif(vif_model)
print("Çıkarılmadan Önceki Vıf Değerleri")
print(vif_degerleri)
# VIF değeri 5'ten büyük olan değişkenleri çıkarıyoruz
yuksek_vif <- names(vif_degerleri[vif_degerleri > 5])
if(length(yuksek_vif) > 0) {
  veri_temiz <- veri_temiz %>% dplyr::select(-one_of(yuksek_vif))
  cat("VIF > 5 olan şu değişkenler modelden çıkarıldı:", paste(yuksek_vif, collapse = ", "), "\n")
}
# BÖLÜM 3: ÇAPRAZ DOĞRULAMA (RESAMPLING) VE VERİ SETİ AYRIMI
# 10-Katlı Çapraz Doğrulama
cv_kontrol <- trainControl(method = "cv", number = 10, savePredictions = "final")
# Regresyon için
veri_regresyon <- veri_temiz
# Sınıflandırma için
q3_degeri <- quantile(veri_regresyon$MonthlyIncome, 0.75, na.rm = TRUE)
veri_siniflandirma <- veri_regresyon %>%
  mutate(IncomeClass = as.factor(ifelse(MonthlyIncome >= q3_degeri, "High_Income",
"Standard_Income"))) %>%
  dplyr::select(-MonthlyIncome)
```

```
# BÖLÜM 4: SINIFLANDIRMA MODELLERİ VE İNDİRGENMİŞ MODEL (CLASSIFICATION)

set.seed(123)

trainIndex_c <- createDataPartition(veri_siniflandirma$IncomeClass, p = 0.80, list = FALSE)

train_class <- veri_siniflandirma[trainIndex_c, ]

test_class  <- veri_siniflandirma[-trainIndex_c, ]

set.seed(123)

train_class_bal <- upSample(x = train_class[, -ncol(train_class)], y = train_class$IncomeClass, yname =
"IncomeClass")

# 5 Farklı Model Eğitimi

set.seed(123)

mod_logreg <- train(IncomeClass ~ ., data = train_class_bal, method = "glm", family = "binomial",
trControl = cv_kontrol)

set.seed(123)

mod_lda    <- train(IncomeClass ~ ., data = train_class_bal, method = "lda", trControl = cv_kontrol)

set.seed(123)

mod_knn_c  <- train(IncomeClass ~ ., data = train_class_bal, method = "knn", tuneLength = 5,
trControl = cv_kontrol)

set.seed(123)

mod_svm_c  <- train(IncomeClass ~ ., data = train_class_bal, method = "svmRadial", tuneLength = 5,
trControl = cv_kontrol)

set.seed(123)

mod_rf_c   <- train(IncomeClass ~ ., data = train_class_bal, method = "rf", tuneLength = 3, ntree =
100, trControl = cv_kontrol)

# Sınıflandırma Ana Model RF %20 Performans

test_tahmin_ana_c <- predict(mod_rf_c, newdata = test_class)

print("Sınıflandırma Ana Model Matrisi")

confusionMatrix(test_tahmin_ana_c, test_class$IncomeClass, positive = "High_Income")


# Sınıflandırma Karşılaştırma Grafikleri

res_class <- resamples(list(LogReg=mod_logreg, LDA=mod_lda, KNN=mod_knn_c, SVM=mod_svm_c,
RF=mod_rf_c))

bwplot(res_class, main="Sınıflandırma Modelleri Karşılaştırması")

dotplot(res_class, main="Sınıflandırma Modelleri Karşılaştırması(Nokta Grafiği)")
```

```
summary(res_class)

# Sınıflandırma İçin İndirgenmiş Model

onem_class <- varImp(mod_rf_c)

plot(onem_class, top = 10, main = "Sınıflandırma: En Önemli 10 Değişken")

# En önemli 5 değişkeni alıp indirgenmiş model kurmak için

en_onemliler_c <- rownames(onem_class$importance)[order(onem_class$importance$Overall,
decreasing = TRUE)[1:5]]

formul_indirgenmis_c <- as.formula(paste("IncomeClass ~", paste(en_onemliler_c, collapse = " + ")))

set.seed(123)

mod_rf_indirgenmis_c <- train(formul_indirgenmis_c, data = train_class_bal, method = "rf",
tuneLength = 3, ntree = 100, trControl = cv_kontrol)

test_tahmin_c <- predict(mod_rf_indirgenmis_c, newdata = test_class)

print("=== SINIFLANDIRMA İNDİRGENMİŞ MODEL (TEST SETİ) KARIŞIKLIK MATRİSİ ===")

confusionMatrix(test_tahmin_c, test_class$IncomeClass, positive = "High_Income")

# BÖLÜM 5: REGRESYON MODELLERİ VE İNDİRGENMİŞ MODEL

set.seed(123)

trainIndex_r <- createDataPartition(veri_regresyon$MonthlyIncome, p = 0.80, list = FALSE)

train_reg <- veri_regresyon[trainIndex_r, ]

test_reg  <- veri_regresyon[-trainIndex_r, ]

# 5 Farklı Model Eğitimi

set.seed(123)

mod_lm     <- train(MonthlyIncome ~ ., data = train_reg, method = "lm", trControl = cv_kontrol)

set.seed(123)

mod_glmnet <- train(MonthlyIncome ~ ., data = train_reg, method = "glmnet", tuneLength = 5,
trControl = cv_kontrol)

set.seed(123)

mod_knn_r  <- train(MonthlyIncome ~ ., data = train_reg, method = "knn", tuneLength = 5, trControl
= cv_kontrol)

set.seed(123)

mod_svm_r  <- train(MonthlyIncome ~ ., data = train_reg, method = "svmRadial", tuneLength = 5,
trControl = cv_kontrol)

set.seed(123)
```

```
mod_rf_r   <- train(MonthlyIncome ~ ., data = train_reg, method = "rf", tuneLength = 3, ntree = 100, trControl = cv_kontrol)

# Regresyon Ana Model RF %20 Performans

test_tahmin_ana_r <- predict(mod_rf_r, newdata = test_reg)

print("Regresyon Ana Model Performans")

postResample(pred = test_tahmin_ana_r, obs = test_reg$MonthlyIncome)

# Regresyon Karşılaştırma Grafikleri

res_reg <- resamples(list(LM=mod_lm, GLMNET=mod_glmnet, KNN=mod_knn_r, SVM=mod_svm_r, RF=mod_rf_r))

bwplot(res_reg, main="Regresyon Modelleri Karşılaştırması")

dotplot(res_reg, main="Regresyon Modelleri Karşılaştırması (Nokta Grafiği")

summary(res_reg)

# Regresyon İçin İndirgenmiş Model

onem_reg <- varImp(mod_rf_r)

plot(onem_reg, top = 10, main = "Regresyon: En Önemli 10 Değişken")

# En önemli 5 değişkeni alıp indirgenmiş modeli kurmak için

en_onemliler_r <- rownames(onem_reg$importance)[order(onem_reg$importance$Overall, decreasing = TRUE)[1:5]]

formul_indirgenmis_r <- as.formula(paste("MonthlyIncome ~", paste(en_onemliler_r, collapse = " + ")))

set.seed(123)

mod_rf_indirgenmis_r <- train(formul_indirgenmis_r, data = train_reg, method = "rf", tuneLength = 3, ntree = 100, trControl = cv_kontrol)

test_tahmin_r <- predict(mod_rf_indirgenmis_r, newdata = test_reg)

print("Regresyon İndirgenmiş Model Performans")

postResample(pred = test_tahmin_r, obs = test_reg$MonthlyIncome)
```